Ocena silników OCR i modeli wizyjno-językowych w rozpoznawaniu tekstu polskiego na danych syntetycznych

[TODO: Autor 1], [TODO: Autor 2], and [TODO: Autor 3]

[TODO: Uczelnia, wydział]
[TODO: e-mail]

Streszczenie Systemy OCR i modele wizyjno-językowe (VLM) trenowane są głównie na danych angielskich, przez co gorzej radzą sobie ze znakami diakrytycznymi innych języków. Przenosimy protokół badania Yılmaza i in. [10] z języka tureckiego na polski: generujemy syntetyczny zbiór obrazów z *Lalki* B. Prusa (tekst drukowany i odręczny), kontrolując obecność polskich znaków, długość słowa, kontekst zdania i pięć rodzajów zniekształceń. Porównujemy [TODO: liczba] modeli: Tesseract i EasyOCR z modelami polskimi, PaddleOCR, TrOCR oraz Qwen2.5-VL. [TODO: Główny wynik w jednym zdaniu.] Pokazujemy też, że słownik znaków PaddleOCR dla języków łacińskich nie zawiera liter ń, ś, ź, ż, co wyklucza ich poprawne rozpoznanie. Kod i dane udostępniamy publicznie.

Słowa kluczowe: OCR · modele wizyjno-językowe · język polski · dane syntetyczne · znaki diakrytyczne

1 Wprowadzenie

[TODO: 1 akapit: OCR, VLM, problem języków innych niż angielski.]

Yılmaz i in. [10] zaproponowali syntetyczny benchmark dla języka tureckiego i pokazali, że znaki specyficzne dla języka są główną trudnością dla większości modeli. Język polski ma dziewięć liter z diakrytykami (ą, ć, ę, ł, ń, ó, ś, ź, ż), z których część różni się od liter łacińskich jedynie drobnym znakiem (ogonek, kreska, kropka).

Cel. Celem artykułu jest ocena, jak dokładnie dostępne lokalnie silniki OCR i otwarty model VLM rozpoznają tekst polski oraz jak na wynik wpływają polskie znaki, długość słowa, kontekst zdania, typ tekstu i zniekształcenia obrazu.

Elementy nowości: (1) przeniesienie protokołu [10] na język polski wraz z otwartym generatorem; (2) uwzględnienie klasycznych silników z modelem polskim (Tesseract `pol`, EasyOCR `pl`), których autorzy nie badali; (3) analiza błędów wyłącznie diakrytycznych i ograniczeń słowników znaków; (4) weryfikacja odtwarzalności badania bazowego.

2 Przegląd literatury

[TODO: Krótko: Tesseract [9], PP-OCR [6], TrOCR [7], VLM [1]; dane syntetyczne [3,2]; benchmark turecki [10]; prace o OCR dla polskiego (do uzupełnienia, max 10 pozycji łącznie).]

3 Materiał i metody

3.1 Zbiór danych

Tekst źródłowy to *Lalka, tom pierwszy* [8] (domena publiczna). Pulę słów stanowią wyrazy co najmniej trzyliterowe występujące w tekście co najmniej dwa razy (8720 słów), a pulę zdań – zdania liczące 4–8 słów, złożone wyłącznie z liter i interpunkcji (680 zdań). Obrazy generujemy biblioteką TRDG 1.8.0 [2] z parametrami autorów badania bazowego: wysokość 64 px, marginesy 15 px, czarny tekst na białym tle. Tekst drukowany renderujemy 15 fontami (Open Sans, Roboto, Source Sans 3), a odręczny 19 popularnymi fontami odręcznymi z Google Fonts. Każdy font sprawdzamy w tabeli `cmap` pod kątem wszystkich znaków korpusu, aby wykluczyć brakujące glify.

Dla każdego typu tekstu (drukowany, odręczny) tworzymy cztery kategorie: (1) słowa z polskimi znakami i bez nich, (2) słowa krótkie (<10 znaków) i długie (>10), (3) pojedyncze słowo i zdanie, (4) zniekształcenia: obraz czysty, rozmycie (promień 2), obrót (do $\pm 16°$), szum gaussowski ($\sigma = 50$) i niska rozdzielczość (wysokość 40 px), stosowane do tych samych słów. Daje to 22 komórki po n obrazów; [TODO: wyniki wstępne: $n = 20$ (440 obrazów); docelowo $n = 100$ (2200)]. Losowanie jest deterministyczne (stałe ziarno), a mniejsza próba jest podzbiorem większej.

3.2 Modele

- **Tesseract** 5.5 [9], model `pol`, tryb jednej linii (`-psm 7`);
- **EasyOCR** [4], model `pl`;
- **PaddleOCR** 2.9 (PP-OCRv4) [6], model `pl`;
- **TrOCR** large-printed [7], model angielski, jak w badaniu bazowym, z domyślnym limitem 21 tokenów wyjścia (co skraca dłuższe zdania, także u autorów);
- **Qwen2.5-VL** [1] [TODO: 3B/7B], prompt autorów z „Turkish” zamienionym na „Polish”.

Modele klasyczne uruchamiamy na CPU, [TODO: Qwen: CPU (3B) / Colab GPU (7B)].

3.3 Miary

Niech t_i oznacza tekst wzorcowy, a p_i predykcję modelu dla obrazu i, oba po normalizacji (Unicode NFC, małe litery, scalone białe znaki). Główną miarą jest współczynnik błędów znakowych

$$\mathrm{CER}_i = \min\left(1,\ \frac{S_i + D_i + I_i}{N_i}\right), \tag{1}$$

gdzie S_i, D_i, I_i to liczby podstawień, usunięć i wstawień znaków w minimalnym ciągu edycji (odległość Levenshteina [5]), a $N_i = |t_i|$ to liczba znaków wzorca. Obcięcie do 1 odpowiada protokołowi [10]: predykcja dłuższa od wzorca nie może dać błędu powyżej 100%. Współczynnik błędów słów WER_i liczymy tym samym wzorem na ciągach słów i podajemy tylko dla zdań, bo dla pojedynczego słowa przyjmuje on wartości 0 lub 1.

Wynik dla zbioru obrazów A (komórki, typu tekstu lub całego zbioru) to średnia

$$\overline{\mathrm{CER}}(A) = \frac{1}{|A|}\sum_{i \in A} \mathrm{CER}_i. \tag{2}$$

Wpływ polskich znaków na błędy opisujemy odsetkiem *błędów wyłącznie diakrytycznych*: wśród błędnych predykcji $E = \{i : p_i \neq t_i\}$ liczymy te, które stają się poprawne po usunięciu diakrytyków funkcją $s(\cdot)$ (ą→a, ł→l itd.):

$$R_{\mathrm{diakr}} = \frac{|\{i \in E : s(p_i) = s(t_i)\}|}{|E|}. \tag{3}$$

3.4 Analiza statystyczna

Niepewność średniej (2) szacujemy jak w [10] nieparametrycznym bootstrapem: z wartości CER_i losujemy ze zwracaniem $B = 1000$ prób o liczności $|A|$, a 95% przedział ufności wyznaczają percentyle 2,5 i 97,5 rozkładu średnich z prób. Wpływ czynnika (np. obecności polskich znaków) mierzymy różnicą średnich między grupą z czynnikiem A i grupą odniesienia B:

$$\Delta = \overline{\mathrm{CER}}(A) - \overline{\mathrm{CER}}(B), \tag{4}$$

np. A – słowa z polskimi znakami, B – słowa bez nich; dla zniekształceń B to obrazy czyste. Przedział ufności dla Δ wyznaczamy, losując niezależnie obie grupy; efekt uznajemy za istotny, gdy przedział nie zawiera zera. Ziarno generatora losowego jest stałe, więc wyniki są powtarzalne.

4 Wyniki

Tabela 1 przedstawia wyniki zbiorcze, a tabela 2 – wyniki w komórkach.

[TODO: Opis wyników po kategoriach (tab. 3): polskie znaki, długość, kontekst, zniekształcenia, typ tekstu.]

Tabela 1. Średni CER (2) według typu tekstu z 95% przedziałem ufności (bootstrap), WER dla zdań, odsetek błędów wyłącznie diakrytycznych (3) i czas na obraz (CPU).

Model	CER				WER	Diakr.	s/obraz
	druk	pismo	razem	95% CI	zdania	[%]	
Tesseract	.114	.329	.221	[.191, .254]	.210	4	0.10
EasyOCR	.085	.257	.171	[.147, .199]	.392	8	0.12
PaddleOCR	.111	.261	.186	[.162, .213]	.489	24	0.05
TrOCR	.122	.283	.202	[.182, .226]	.601	25	4.21

Tabela 2. Średni CER w komórkach: tekst drukowany / odręczny.

Podkategoria	Tesseract	EasyOCR	PaddleOCR	TrOCR
z polskimi znakami	.006 / .149	.006 / .192	.180 / .383	.204 / .268
bez polskich znaków	.000 / .232	.000 / .113	.000 / .110	.023 / .094
krótkie słowa	.000 / .110	.000 / .084	.106 / .243	.131 / .216
długie słowa	.000 / .131	.004 / .078	.070 / .087	.070 / .117
słowo	.000 / .096	.000 / .107	.115 / .199	.125 / .210
zdanie	.004 / .196	.025 / .250	.080 / .107	.187 / .249
czysty	.000 / .133	.000 / .124	.064 / .243	.075 / .206
rozmycie	.018 / .507	.273 / .730	.114 / .268	.099 / .567
obrót	.029 / .359	.000 / .164	.064 / .183	.075 / .190
szum	.723 / .954	.000 / .164	.069 / .216	.075 / .229
niska rozdzielczość	.471 / .752	.627 / .819	.363 / .837	.281 / .761

Tabela 3. Wpływ czynników: różnica średniego CER Δ (4) między grupą z czynnikiem a grupą odniesienia (dla zniekształceń: obrazy czyste). Pogrubienie: 95% przedział ufności nie zawiera zera.

Czynnik	Tesseract	EasyOCR	PaddleOCR	TrOCR
polskie znaki	-.038	+.043	**+.226**	**+.178**
długie słowa	+.010	-.001	**-.096**	**-.080**
zdanie zamiast słowa	+.052	**+.084**	**-.063**	+.051
pismo odręczne	**+.215**	**+.172**	**+.150**	**+.160**
rozmycie	**+.196**	**+.439**	+.037	**+.193**
obrót	**+.128**	+.020	-.030	-.008
szum	**+.772**	+.020	-.011	+.012
niska rozdzielczość	**+.545**	**+.661**	**+.446**	**+.381**

5 Dyskusja

Słowniki znaków. PaddleOCR dla języka polskiego korzysta ze wspólnego modelu łacińskiego, którego słownik (`latin_dict.txt`) zawiera litery ą, ć, ę, ł, ó, ale nie zawiera ń, ś, ź, ż. Model nie może więc ich zwrócić i zastępuje je literami podobnymi (np. „ludności" zamiast „ludności").

Odtwarzalność badania bazowego. Autorzy udostępnili dane, kod i predykcje dla każdego obrazu. Ponowne uruchomienie ośmiu otwartych modeli na warstwowej próbie 1650 obrazów dało średni CER różniący się od opublikowanych predykcji najwyżej o 0,001, a w przypadku Pixtrala o 0,007. Predykcje identyczne z opublikowanymi stanowiły od 90,4% do 99,9%, poza Pixtralem (28,3%). Kod autorów zamiast wzoru (1) liczy

$$\mathrm{CER}_i^{\mathrm{kod}} = \frac{S_i + D_i + I_i}{|p_i|}, \tag{5}$$

czyli dzieli przez długość predykcji, a nie wzorca (zamienione argumenty funkcji); tak policzone są wartości w opublikowanym pliku z predykcjami. Liczby z tekstu artykułu (np. TrOCR 0,38) odtwarza natomiast inny wariant z ich repozytorium: wzór (1) po usunięciu spacji i interpunkcji, czego artykuł nie opisuje. Zmienia to ranking: GOT-OCR2, który gubi spacje, ma w tym wariancie CER 0,311, a wzorem (1) 0,391.

[TODO: Porównanie z wynikami tureckimi (tylko jakościowo).]

6 Ograniczenia i dalsze prace

Dane są syntetyczne, jednoliniowe i na białym tle (tekstury papieru z badania bazowego nie zostały udostępnione); pominięto tekst w scenie i zdjęcia rzeczywiste. [TODO: Mała próba / jeden korpus / mniejszy wariant Qwen.]

7 Wnioski

[TODO: 3–4 zdania.]

Dostępność danych i kodu. Generator, skrypty uruchomieniowe, wyniki dla każdego obrazu i zbiór obrazów: [TODO: adres repozytorium]. Kod na licencji MIT, dane na licencji CC BY 4.0.

Bibliografia

1. Bai, S., et al.: Qwen2.5-VL technical report (2025)
2. Belval, E.: TextRecognitionDataGenerator. `https://github.com/Belval/TextRecognitionDataGenerator`, wersja 1.8.0, dostęp: 22.10.2026
3. Jaderberg, M., Simonyan, K., Vedaldi, A., Zisserman, A.: Synthetic data and artificial neural networks for natural scene text recognition (2014)

4. JaidedAI: EasyOCR: Ready-to-use OCR with 80+ supported languages. https://github.com/JaidedAI/EasyOCR, dostęp: 22.10.2026
5. Levenshtein, V.I.: Binary codes capable of correcting deletions, insertions, and reversals. Soviet Physics Doklady **10**(8), 707–710 (1966)
6. Li, C., Liu, W., Guo, R., Yin, X., Jiang, K., Du, Y., Du, Y., Zhu, L., Lai, B., Hu, X., Yu, D., Ma, Y.: PP-OCRv3: More attempts for the improvement of ultra lightweight OCR system (2022)
7. Li, M., Lv, T., Chen, J., Cui, L., Lu, Y., Florencio, D., Zhang, C., Li, Z., Wei, F.: TrOCR: Transformer-based optical character recognition with pre-trained models. In: Proceedings of the AAAI Conference on Artificial Intelligence. vol. 37, pp. 13094–13102 (2023). https://doi.org/10.1609/aaai.v37i11.26538
8. Prus, B.: Lalka, tom pierwszy. Wolne Lektury, https://wolnelektury.pl/katalog/lektura/lalka-tom-pierwszy/, domena publiczna, dostęp: 22.10.2026
9. Smith, R.: An overview of the Tesseract OCR engine. In: Ninth International Conference on Document Analysis and Recognition (ICDAR 2007). pp. 629–633 (2007). https://doi.org/10.1109/ICDAR.2007.4376991
10. Yılmaz, Y., Hanoğlu, E.G., Özkan, A.G., Öztoprak, K.: Benchmarking OCR and vision-language models for Turkish text recognition: a comprehensive evaluation using synthetic data. International Journal on Document Analysis and Recognition (IJDAR) (2026). https://doi.org/10.1007/s10032-026-00613-6