Benchmarking OCR and vision-language models for Turkish text recognition

Artykuł bazowy: Y. Yılmaz, E. G. Hanoğlu, A. G. Özkan, K. Öztoprak
International Journal on Document Analysis and Recognition, 2026,
doi:10.1007/s10032-026-00613-6

[Imię Nazwisko], [Imię Nazwisko], [Imię Nazwisko]

Laboratorium, 7 listopada 2026

Czasopismo i autorzy

IJDAR, Springer, ISSN 1433-2833 / 1433-2825

- wykaz MNiSW: **100 pkt**, dyscyplina informatyka techniczna i telekomunikacja
- Impact Factor: **2,480** (JCR 2025), 3,630 (JCR 2024)[1]
- SJR: Q2, CiteScore 6,7[2]
- indeks h czasopisma: 75[3]
- typ: *original paper* (nowe badania)

Konya Food and Agriculture University, Turcja

Autor	indeks h[3]
Yasin Yılmaz	b.d.[4]
Erol Görkem Hanoğlu	0
Ayşe Gül Özkan	1
Kasım Öztoprak	11

[1] SciJournal na podstawie JCR (Clarivate); do potwierdzenia w JCR.

[2] Editage/SCImago.

[3] OpenAlex, stan na 22.10.2026.

[4] ORCID 0009-0008-3985-4624 bez profilu w OpenAlex; popularne nazwisko uniemożliwia jednoznaczne przypisanie.

Cel, słowa kluczowe, nowość

Słowa kluczowe: OCR, VLMs, Turkish text recognition, synthetic dataset

Cel: pierwsza systematyczna ocena klasycznego OCR i modeli wizyjno-językowych (VLM) w rozpoznawaniu tekstu tureckiego, języka o mniejszych zasobach treningowych (znaki ç, ğ, ı, İ, ö, ş, ü; język aglutynacyjny, długie słowa).

Elementy nowości:

- syntetyczny zbiór 13 200 obrazów z kontrolowanymi kategoriami trudności,
- 10 modeli trzech typów porównanych w jednym protokole,
- analiza wpływu znaków tureckich, długości słowa, kontekstu zdania i zniekształceń,
- otwarte dane (Zenodo, CC BY 4.0) i kod (GitHub).

Materiał

- Teksty: *Nutuk* Atatürka (6600 obrazów) i turecka Wikipedia (6600) oraz 90 zdjęć rzeczywistych (*Gold Standard*).
- Generator TRDG 1.8.0; trzy typy tekstu: **drukowany**, **odręczny** (fonty Google Fonts), **tekst w scenie** (tła COCO).
- Cztery kategorie, po 200 obrazów na komórkę:
  1. ze znakami tureckimi / bez nich,
  2. słowa krótkie / długie (próg 10 znaków),
  3. pojedyncze słowo / zdanie,
  4. zniekształcenia: czysty, obrót, szum, rozmycie, niska rozdzielczość.

Metody

- **Klasyczne OCR:** TrOCR (large-printed), PaddleOCR.
- **Otwarte VLM:** Qwen2.5-VL-7B, InternVL3-8B, DeepSeek-VL2-tiny, Phi-3.5-Vision, Pixtral-12B, GOT-OCR2.
- **Komercyjne VLM:** GPT-4o, Claude.
- Ten sam prompt dla VLM: *„Extract the Turkish text from the image exactly as it appears. . . ”*
- Miary: **CER** (główna) i **WER** (zdania), biblioteka jiwer; małe litery (TrOCR zwraca same wielkie), CER obcięty do 1,0; przedziały ufności 95% metodą bootstrap.

Wyniki

- Najlepsze: **GPT-4o** i **Qwen2.5-VL-7B**; otwarty Qwen dorównuje komercyjnemu modelowi.
- Najgorszy: TrOCR (CER 0,38).
- Znaki tureckie pogarszają wynik wszystkich modeli poza GPT-4o (0,055 / 0,065).
- Długość słowa nie ma dużego wpływu; najtrudniejsze są **pismo odręczne** i **niska rozdzielczość**.

Średni CER (przeliczony z ich danych, 6600 obrazów):

Model	CER
GPT-4o	0,070
Qwen2.5-VL-7B	0,077
InternVL3-8B	0,182
DeepSeek-VL2-tiny	0,191
Phi-3.5-Vision	0,238
PaddleOCR	0,310
Claude	0,349
Pixtral-12B	0,370
TrOCR	0,383
GOT-OCR2	0,391

Odtwarzalność: co sprawdziliśmy

Dane (Zenodo, CC BY 4.0) i kod (GitHub, bez licencji) są dostępne, a repozytorium zawiera predykcje każdego modelu dla każdego obrazu.

- **Przeliczenie:** z ich predykcji odtwarzamy liczby z tekstu (TrOCR 0,383 wobec 0,38; GPT-4o na czystych obrazach 0,017 wobec 0,017).
- **Ponowne uruchomienie** PaddleOCR na 330 obrazach (10 na komórkę): **99,7% predykcji identycznych** z predykcjami autorów.
- **Rozbieżności:**
  - kod liczy CER jako odległość / długość *predykcji*, a nie prawdy;
  - opublikowane wyniki dotyczą Claude 3.7 Sonnet (CER 0,349), w tekście 0,197;
  - tekstury tła papieru nie zostały udostępnione.

Ograniczenia i nasz wkład

Ograniczenia (wg autorów): dane syntetyczne, jedna linia tekstu, mały zbiór rzeczywisty, brak dostrajania modeli.

Nasze badanie: ta sama metodologia dla **języka polskiego** (ą, ć, ę, ł, ń, ó, ś, ź, ż):

- zbiór syntetyczny z *Lalki* B. Prusa (Wolne Lektury, domena publiczna): druk i pismo odręczne, te same kategorie;
- modele: Qwen2.5-VL, PaddleOCR, TrOCR oraz **Tesseract (pol)** i **EasyOCR (pl)**, czyli klasyczne OCR z modelem polskim, których autorzy nie badali;
- poprawiona miara CER, otwarty kod i dane.