Benchmarking OCR and vision-language models for Turkish text recognition: a comprehensive evaluation using synthetic data

Y. Yılmaz, E. G. Hanoğlu, A. G. Özkan, K. Öztoprak
International Journal on Document Analysis and Recognition, Springer, 2026,
doi:10.1007/s10032-026-00613-6

Marek Siuzdak, Maciej Pietras, Anton Ovod, Paweł Podgórski

8.11.2026

Czasopismo, wydawca i autorzy

Czasopismo	*International Journal on Document Analysis and Recognition* (IJDAR)
Wydawnictwo	Springer (Springer Nature)
Impact Factor	**1,7**; pięcioletni 2,3 (2025)
Punkty ministerialne	**100** (informatyka techniczna i telekomunikacja)
Tytuł artykułu	*Benchmarking OCR and vision-language models for Turkish text recognition: a comprehensive evaluation using synthetic data*
Typ artykułu	Original Paper (nowe badania)

Autor	Indeks *h*
Yasin Yılmaz	0
Erol Görkem Hanoğlu	0
Ayşe Gül Özkan	5
Kasım Öztoprak	9

Afiliacja wszystkich autorów: Computer Engineering, Konya Food and Agriculture University, Turcja.

Źródła: strona czasopisma (Springer), wykaz ministerialny z 5.01.2024, Scopus; stan na 2.11.2026.

Cel artykułu i pytania badawcze

Cel

Ocenić, jak dokładnie klasyczne silniki OCR i modele wizyjno-językowe (VLM) odczytują tekst turecki i sprawdzić, czy wyniki z danych syntetycznych przenoszą się na prawdziwe zdjęcia.

Autorzy szukają odpowiedzi na cztery pytania:

1. Czy litery tureckie (ç, ğ, ı, İ, ö, ş, ü) zwiększają błąd odczytu?
2. Czy długie słowa, typowe dla aglutynacyjnego tureckiego, są trudniejsze od krótkich?
3. Czy kontekst zdania pomaga w porównaniu z pojedynczym słowem?
4. Jak na błąd wpływają zniekształcenia obrazu i typ tekstu (druk, pismo odręczne, tekst w scenie)?

Słowa kluczowe: OCR, VLMs, Turkish text recognition, Synthetic dataset

Materiał: zbiór syntetyczny i zdjęcia

Źródło tekstu	Obrazy
Nutuk Atatürka, syntetyczne	6600
Turecka Wikipedia, syntetyczne	6600
Gold Standard, zdjęcia	90

Typ tekstu	Jak powstał
Druk	13 czcionek na tle papieru
Pismo	340 czcionek odręcznych
Scena	napis wklejony w zwykłe zdjęcia
Zdjęcia	szyldy, skany, notatki (6 × 15)

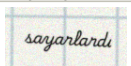
Kategoria	Podkategorie
Litery tureckie	z nimi, bez nich
Długość słowa	poniżej 10, ponad 10 znaków
Kontekst	pojedyncze słowo, zdanie
Zniekształcenia	czysty, obrót, szum, rozmycie, niska rozdzielczość

Generowanie obrazów	
Obrazy	3 typy × 11 podkategorii × 200
Narzędzie	generator TRDG 1.8.0

Typy tekstu (zbiór syntetyczny)



druk



pismo odręczne



tekst w scenie

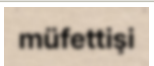
Zniekształcenia (ten sam tekst)



obrót



szum

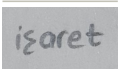


rozmycie



niska rozdz.

Gold Standard



zdjęcie: pismo

Przykłady: zbiór autorów na Zenodo, DOI 10.5281/zenodo.21923181 (CC BY 4.0).

Metody: modele i miary błędu

10 modeli, bez douczania

OCR	PaddleOCR, TrOCR, GOT-OCR 2.0
Otwarte VLM	Qwen2.5-VL 7B, InternVL3 8B, DeepSeek-VL2 Tiny, Phi-3.5-Vision, Pixtral 12B
Komercyjne VLM	GPT-4o, Claude Sonnet 4

Google Colab, GPU Nvidia A100; każdy model odczytuje 13 200 obrazów syntetycznych i 90 prawdziwych zdjęć.

Polecenie dla VLM: *„Extract the Turkish text from the image exactly as it appears. . . ”*

Miary błędu i analiza

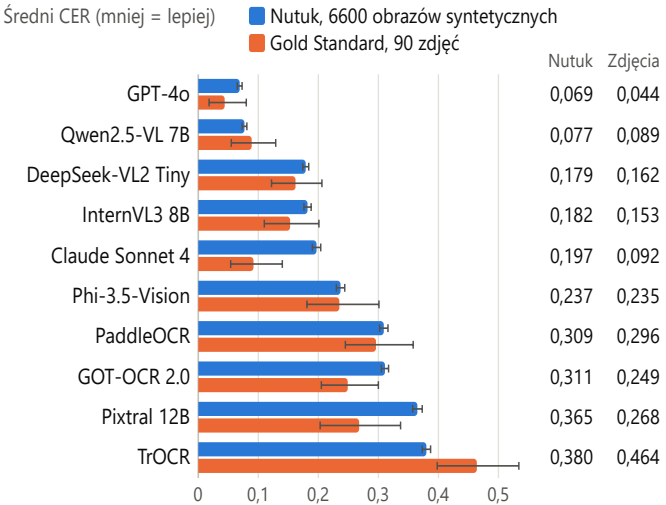
CER (błąd znakowy) $= \dfrac{S + D + I}{N}$

S, D, I: znaki podmienione, pominięte i dopisane przez model; N: długość prawdziwego tekstu. CER $= 0{,}1$ to średnio jeden zły znak na dziesięć.

WER (błąd wyrazowy): to samo na słowach, tylko dla zdań.

- Wielkość liter pomijana; CER powyżej 1 (gdy model dopisze wiele znaków) liczony jako 1.
- Przedziały ufności 95%: metoda bootstrap.
- Zgodność rankingów modeli na zdjęciach i syntetykach: korelacja Spearmana.
- Litery tureckie: odsetek odczytanych poprawnie.

Wyniki: ranking modeli i walidacja na zdjęciach



Kreski: 95% przedziały ufności (bootstrap).

- GPT-4o i otwarty Qwen2.5-VL wyraźnie przed resztą.
- Claude Sonnet 4: 5. na syntetykach, 3. na zdjęciach.
- TrOCR ostatni na obu zbiorach.
- Ranking na zdjęciach prawie taki sam jak na danych syntetycznych (Spearman $\rho = 0{,}92$, $p < 0{,}001$).
- Wikipedia: CER średnio o 3% wyższy, kolejność prawie bez zmian.

Wyniki: czynniki utrudniające odczyt

CER 0 – 0,66

	Litery tureckie		Typ tekstu			Zniekształcenie					Długość słowa		Kontekst	
	bez	z	druk	scena	pismo	czysty	obrót	szum	rozmycie	niska rozdz.	poniżej 10	ponad 10	słowo	zdanie
GPT-4o	0,07	0,07	0,03	0,04	0,14	0,02	0,03	0,06	0,10	0,15	0,09	0,07	0,08	0,05
Qwen2.5-VL 7B	0,03	0,08	0,04	0,05	0,14	0,04	0,07	0,08	0,10	0,19	0,09	0,06	0,07	0,04
DeepSeek-VL2 Tiny	0,07	0,19	0,14	0,15	0,25	0,15	0,15	0,19	0,22	0,28	0,22	0,17	0,20	0,13
InternVL3 8B	0,11	0,21	0,14	0,12	0,29	0,13	0,14	0,19	0,23	0,27	0,22	0,18	0,21	0,12
Claude Sonnet 4	0,15	0,17	0,09	0,24	0,27	0,09	0,17	0,20	0,27	0,41	0,20	0,17	0,18	0,15
Phi-3.5-Vision	0,14	0,24	0,15	0,25	0,31	0,14	0,15	0,27	0,30	0,31	0,27	0,22	0,25	0,33
PaddleOCR	0,14	0,29	0,22	0,33	0,37	0,26	0,27	0,37	0,30	0,56	0,34	0,29	0,32	0,25
GOT-OCR 2.0	0,16	0,32	0,21	0,34	0,38	0,23	0,24	0,48	0,35	0,35	0,37	0,30	0,34	0,28
Pixtral 12B	0,19	0,33	0,28	0,35	0,46	0,27	0,33	0,34	0,46	0,61	0,33	0,33	0,32	0,50
TrOCR	0,16	0,33	0,29	0,40	0,45	0,28	0,36	0,32	0,41	0,66	0,35	0,32	0,34	0,65
Wniosek	z literami gorzej u 9 z 10		pismo najtrudniejsze u wszystkich 10			niska rozdzielczość najtrudniejsza u 9 z 10					długie łatwiejsze u 9 z 10		zdania łatwiejsze u 7 z 10	

Wkład autorów i elementy nowości

Wkład autorów

- Publiczny zbiór: 13 200 obrazów syntetycznych (druk, pismo, scena) i 90 prawdziwych zdjęć.
- Ocena 10 modeli z trzech grup (klasyczny OCR, otwarte i komercyjne VLM) na tych samych obrazach.

Elementy nowości

- Pierwsze porównanie OCR i VLM dla tureckiego (wcześniej tylko klasyczny OCR).
- Wpływ każdego czynnika osobno: te same teksty z różnymi zniekształceniami.
- Błędy dla każdej z 7 liter tureckich.
- Walidacja na zdjęciach: $\rho = 0{,}92$.

Ograniczenia	pismo odręczne z czcionek zamiast prawdziwego, modele bez dostrajania, tylko 90 prawdziwych zdjęć.
Dostęp do danych	zbiór na Zenodo (CC BY 4.0), kod na GitHubie.
Nasze odtworzenie	8 otwartych modeli uruchomionych ponownie: średni CER zgodny z autorami co do 0,001 (poza Pixtralem), ranking modeli taki sam.