Benchmarking OCR and vision-language models for Turkish text recognition: a comprehensive evaluation using synthetic data

Artykuł bazowy: Y. Yılmaz, E. G. Hanoğlu, A. G. Özkan, K. Öztoprak
International Journal on Document Analysis and Recognition, Springer, 2026, doi:10.1007/s10032-026-00613-6

Marek Siuzdak, Maciej Pietras, Anton Ovod, Paweł Podgórski

Laboratorium 4, 7.11.2026

Czasopismo i autorzy

Czasopismo	*International Journal on Document Analysis and Recognition* (IJDAR)
Wydawnictwo	Springer (Springer Nature)
Impact Factor	**1,7**; pięcioletni 2,3 (2025)
Punkty ministerialne	**100** (wykaz z 5.01.2024, poz. 9473, informatyka techniczna i telekomunikacja)
Tytuł artykułu	*Benchmarking OCR and vision-language models for Turkish text recognition: a comprehensive evaluation using synthetic data*
Typ artykułu	Original Paper (nowe badania), online od 21.08.2026

Autor	Indeks *h*
Yasin Yılmaz	0
Erol Görkem Hanoğlu	0
Ayşe Gül Özkan	5
Kasım Öztoprak	9

Wszyscy: Computer Engineering, Konya Food and Agriculture University, Turcja

Źródła: strona czasopisma (Springer), wykaz ministerialny z 5.01.2024, Scopus; stan na 2.11.2026.

Cel artykułu

- Modele OCR i modele wizyjno-językowe (VLM) uczy się głównie na danych z języków o dużych zasobach, np. angielskiego.
- Turecki ma mało danych treningowych, siedem liter swoistych (ç, ğ, ı, İ, ö, ş, ü) i budowę aglutynacyjną, czyli długie słowa.
- Wcześniejsze porównania dla tureckiego nie obejmowały VLM, a brakowało publicznego zbioru z różnymi zniekształceniami.

Cel

Pierwsza systematyczna ocena systemów OCR i modeli VLM w rozpoznawaniu tekstu tureckiego: wpływ liter tureckich, długości słowa, kontekstu zdania, typu tekstu i zniekształceń oraz przenoszenie wyników z danych syntetycznych na zdjęcia.

Słowa kluczowe: OCR, VLMs, Turkish text recognition, Synthetic dataset

Materiał: zbiór danych

Źródło tekstu	Obrazy
Nutuk Atatürka, syntetyczne	6600
Turecka Wikipedia, syntetyczne	6600
Gold Standard, zdjęcia	90

Druk (13 krojów, tła papieru), pismo odręczne (340 fontów Google Fonts), tekst w scenie (tła COCO). Generator TRDG 1.8.0 i własne skrypty. Zdjęcia: 6 podkategorii po 15, bez zniekształceń.

Kategoria	Podkategorie
Litery tureckie	z nimi, bez nich
Długość słowa	poniżej 10, ponad 10 znaków
Kontekst	pojedyncze słowo, zdanie
Zniekształcenia	czysty, obrót, szum, rozmycie, niska rozdzielczość (te same teksty)

3 typy × 11 podkategorii × 200 obrazów = **6600**

Typy tekstu (zbiór syntetyczny)



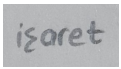
druk | pismo odręczne | tekst w scenie

Zniekształcenia (ten sam tekst)



obrót | szum | rozmycie | niska rozdz.

Gold Standard



zdjęcie: pismo

Przykłady: zbiór autorów na Zenodo, DOI 10.5281/zenodo.21923181 (CC BY 4.0), część Wikipedia i Gold Standard.

Metody: modele i ocena

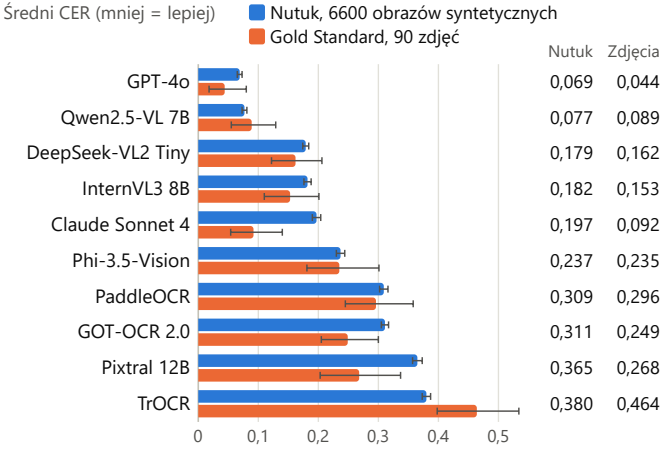
10 modeli bez douczania na tureckim:

OCR	PaddleOCR, TrOCR, GOT-OCR 2.0
Otwarte VLM	Qwen2.5-VL 7B, InternVL3 8B, DeepSeek-VL2 Tiny, Phi-3.5-Vision, Pixtral 12B
Komercyjne VLM	GPT-4o, Claude Sonnet 4 (przez API)

Google Colab, GPU Nvidia A100; każdy model odczytuje $13\,200 + 90$ obrazów.

- Polecenie dla VLM: *„Extract the Turkish text from the image exactly as it appears...”*; odpowiedzi z komentarzem powtórzono z ostrzejszym poleceniem (74 przypadki, 0,56%).
- Miary: CER $= (S + D + I)/N$ (główna) i WER (tylko zdania).
- Przed liczeniem małe litery (TrOCR zwraca same wielkie), CER obcięty do 1.
- Statystyka: bootstrap 95% (1000 losowań), korelacja Spearmana między zdjęciami a danymi syntetycznymi.
- Litery tureckie: dopasowanie Levenshteina.

Wyniki: porównanie modeli



Wartości odczytane z rys. 3 i 11 artykułu; kreski: przedziały 95% (bootstrap).

- GPT-4o i otwarty Qwen2.5-VL wyraźnie przed resztą.
- Claude Sonnet 4 dopiero piąty (0,197), na zdjęciach trzeci (0,092).
- TrOCR ostatni na obu zbiorach.
- Kolejność na zdjęciach zgodna z syntetyczną: $\rho = 0{,}92$, $p < 0{,}001$.
- Wikipedia: CER średnio o 3% wyższy, kolejność prawie bez zmian.

Wyniki: co utrudnia odczyt (zbiór Nutuk)

CER 0 – 0,66

	Litery tureckie		Typ tekstu			Zniekształcenie					Długość słowa		Kontekst	
	bez	z	druk	scena	pismo	czysty	obrót	szum	rozmycie	niska rozdz.	poniżej 10	ponad 10	słowo	zdanie
GPT-4o	0,07	0,07	0,03	0,04	0,14	0,02	0,03	0,06	0,10	0,15	0,09	0,07	0,08	0,05
Qwen2.5-VL 7B	0,03	0,08	0,04	0,05	0,14	0,04	0,07	0,08	0,10	0,19	0,09	0,06	0,07	0,04
DeepSeek-VL2 Tiny	0,07	0,19	0,14	0,15	0,25	0,15	0,15	0,19	0,22	0,28	0,22	0,17	0,20	0,13
InternVL3 8B	0,11	0,21	0,14	0,12	0,29	0,13	0,14	0,19	0,23	0,27	0,22	0,18	0,21	0,12
Claude Sonnet 4	0,15	0,17	0,09	0,24	0,27	0,09	0,17	0,20	0,27	0,41	0,20	0,17	0,18	0,15
Phi-3.5-Vision	0,14	0,24	0,15	0,25	0,31	0,14	0,15	0,27	0,30	0,31	0,27	0,22	0,25	0,33
PaddleOCR	0,14	0,29	0,22	0,33	0,37	0,26	0,27	0,37	0,30	0,56	0,34	0,29	0,32	0,25
GOT-OCR 2.0	0,16	0,32	0,21	0,34	0,38	0,23	0,24	0,48	0,35	0,35	0,37	0,30	0,34	0,28
Pixtral 12B	0,19	0,33	0,28	0,35	0,46	0,27	0,33	0,34	0,46	0,61	0,33	0,33	0,32	0,50
TrOCR	0,16	0,33	0,29	0,40	0,45	0,28	0,36	0,32	0,41	0,66	0,35	0,32	0,34	0,65
Wniosek	z literami gorzej u 9 z 10		pismo najtrudniejsze u wszystkich 10			niska rozdzielczość najtrudniejsza u 9 z 10					długie łatwiejsze u 9 z 10		zdania łatwiejsze u 7 z 10	

- Litery tureckie odczytane poprawnie: GPT-4o 86-94%, Qwen2.5-VL 73-93%, Claude Sonnet 4 69-78%, GOT-OCR 3-5%, TrOCR i PaddleOCR prawie 0%; najtrudniejsze ı i İ.
- WER zdań: GPT-4o 0,11 i Qwen2.5-VL 0,12 wobec 0,83 (GOT-OCR) i 0,87 (TrOCR).

Wartości odczytane z rys. 4-9 i 14 artykułu.

Wkład autorów, nowości i nasza replikacja

Artykuł bazowy: wkład i nowości

- Pierwszy benchmark OCR i VLM dla tureckiego (zniekształcenia, kontekst).
- Publiczny zbiór 13 200 obrazów (druk, pismo, scena) oraz 90 zdjęć.
- Analiza 7 liter tureckich i ocena 10 modeli.
- Walidacja na zdjęciach: $\rho = 0{,}92$ ($p < 0{,}001$).

Ograniczenia wg autorów: pismo z fontów zamiast odręcznego, brak dostrajania, mały zbiór zdjęć (90 szt.).

Nasz wkład: replikacja na Colabie

- Weryfikacja 65 036 wartości CER z plików autorów (pełna zgodność).
- **Uruchomienie 8 modeli na GPU A100** (próbka 1650 obrazów, po 50 na komórkę).
- **Średni CER zgodny do 0,001** (Pixtral 0,007 z braku stałego ziarna).
- Identyczność predykcji: 90,4–100%.

Dane autorów: Zenodo (CC BY 4.0), kod: GitHub. Nasze kody i wyniki replikacji: w dołączonym repozytorium.